



微电子学与计算机  
*Microelectronics & Computer*  
ISSN 1000-7180, CN 61-1123/TN

## 《微电子学与计算机》网络首发论文

题目：基于 U-GCN 的节点分类算法  
作者：叶岱昆, 颜钟棋, 徐嘉忆, 陈奋, 翁伟  
网络首发日期：2024-07-20  
引用格式：叶岱昆, 颜钟棋, 徐嘉忆, 陈奋, 翁伟. 基于 U-GCN 的节点分类算法[J/OL]. 微电子学与计算机. <https://link.cnki.net/urlid/61.1123.tn.20240717.1353.009>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

## 基于 U-GCN 的节点分类算法

叶岱昆<sup>1</sup>, 颜钟棋<sup>1</sup>, 徐嘉忆<sup>1</sup>, 陈 奋<sup>2</sup>, 翁伟<sup>1</sup>

(1 厦门理工学院计算机与信息工程学院, 福建厦门 361000;

2 厦门服云信息科技有限公司, 福建厦门 361000)

**摘 要:** U-GCN(Universal Graph Convolutional Networks)作为一种图神经网络(GNNs)的变体,通过构造多种邻居图并学习三种邻居图的信息来提高算法的泛化能力,能够广泛地应用在复杂多样的图数据上。然而 U-GCN 关注三种邻居图中的信息融合,而忽略了邻居图中蕴含的信息的有效性,这导致部分邻居图中的信息不仅干扰模型的学习,甚至主导模型做出错误判断。针对此问题,提出一种基于 U-GCN 的节点分类方法,通过设计邻居图重要性值并引入到注意力网络中,以提高邻居图之间的结合性。本方法可分为两步,首先,根据图数据中的节点类型、节点标签、节点的边和节点的邻居等属性计算邻居图重要性值;然后,在多头图注意力网络和图注意力网络中引入邻居图重要性值,自适应地改变邻居图的特征向量在信息融合中的权重,提高模型在复杂图数据上的泛化能力。采用多种指标在多个数据集上进行对比实验,实验结果表明,所提出的模型相较于 U-GCN,在多个数据集上均有提升,其中 Texas 数据集上的最高 Macro-F1 指标提升 19.9%,为融合多种邻居图的改进方法提供可靠的参考方案。

**关键词:** 图神经网络;多图融合;节点分类;网络结构信息;注意力机制

**中图分类号:** TP183 **文献标识码:** A

## U-GCN based node classification algorithm

YE Daikun<sup>1</sup>, YAN Zhongqi<sup>1</sup>, XU Jiayi<sup>1</sup>, CHEN Fen<sup>2</sup>, WENG Wei<sup>1</sup>

(1 College of Computer and Information Engineering, Xiamen University of Technology,

Xiamen 361000, Fujian, China;

2 Xiamen Service Cloud Information Technology Co., Ltd, Xiamen 361000, Fujian, China)

**Abstract:** U-GCN (Universal Graph Convolutional Networks), as a variant of graph neural networks (GNNs), improves the generalisation ability of the algorithm by constructing multiple neighbourhood graphs and learning the information in three neighbourhood graphs, which can be widely applied to complex and diverse graph data. However, U-GCN focuses on the fusion of information in the three kinds of neighbourhood graphs and ignores the validity of the information embedded in the neighbourhood graphs, which leads to the fact that some of the information in the neighbourhood graphs not only interferes with the learning of the model, but even dominates the model to make incorrect judgments. To address this problem, a node classification method based on U-GCN is proposed to improve the combination between neighbour graphs by designing the neighbour graph neighbour graph importance value and introducing it into the attention network. This method can be divided into two steps, firstly, the neighbour graph importance value is calculated based on the attributes of node type, node label, node's edges and node's neighbours in the graph data; then, the neighbour graph importance value is introduced into the multi-head graph attention network and the graph attention network, and the weight of the feature vectors of the neighbour graphs in the information fusion is changed adaptively, so as to improve the model's ability to generalize on the complex graph data. Comparison experiments are conducted on multiple datasets using multiple metrics, and the experimental results show that the proposed model improves on multiple datasets compared to U-GCN, among which the highest Macro-F1 metric on Texas dataset improves by 19.9%, which provides a reliable reference scheme for the improvement method of

fusing multiple neighbourhood graphs.

**Key words:** Graph Convolutional Networks; Multi-graph Fusion; Node Classification; Network Structure Information; Attention Mechanisms

## 1 引言

图由节点和边构成,是一种非欧几里德结构(Non-Euclidean Structure)的数据,例如论文引用网络、蛋白质组成网络、网页链接网络等都可视为一种图数据。不同于图片、视频等欧几里德结构(Euclidean Structure)数据,图具有不规则的拓扑结构,节点和边的数量以及连接方式都可能不同。尽管深度学习在欧式结构数据上取得巨大的成功,但在图结构数据上,基于神经网络的深度学习表现得并不好<sup>[1]</sup>。近年来,随着图数据丰富的信息被不断地发掘,利用机器学习对图进行分析的研究受到越来越多的关注<sup>[2]</sup>。特别是图卷积神经网络<sup>[3]</sup>的研究发布,为高效处理图数据提供可靠的参考。节点分类是图领域的一种常见的应用任务,在算法研究中,通常作为下游任务测试模型的分类能力。在生产环境中,广泛应用在推荐系统中的个性化推荐、蛋白质预测中的蛋白质分类等。随着图神经网络<sup>[4]</sup>的发展,图数据所蕴含的信息将受到更层次地发掘和学习,为现实生活提供更广泛应用场景。

当前的图神经网络研究主要关注同质图<sup>[5]</sup>或异质图<sup>[6]</sup>,同时关注两种不同类型的图的研究较少。因此,大多数模型无法在同时在同质图和异质图上取得客观的性能。此外,现实生活中广泛存在同质图和异质图,例如,在蛋白质网络中,不同类型的氨基酸更有可能相互连接<sup>[7]</sup>,图数据表现出强异质性;在交易网络中,欺诈者倾向于与同伙而非其他欺诈者建立联系<sup>[8]</sup>,图数据表现出强同质性。因此,如何有效地同时学习同质图和异质图是当前图神经网络所面临的一个挑战。

针对上述问题,Jin等<sup>[9]</sup>提出的U-GCN方法,使得图神经网络在复杂的图数据能够展现出强大的学习能力。该方法主要有两大关键步骤。其一,构建三种分别由图数据的1阶邻居、2阶邻居和 $k$ 最近邻( $k$ -Nearest Neighbor)邻居组成的邻居网络(图)。其中,1阶、2阶和 $k$ 最近邻三种邻居网络(图)分别适合完全同质性、完全异质性和随机性网络(图)。其二,学习三种邻居图的信息,分别生成三个图级表示。然后在使用图注意力机制自适应地融合三个图级表示中对应的节点表示。实验结果证明,该方法有效地学习图数据中的信息,并且在同质图和异质图数据上表现优异。

然而,U-GCN的方法默认邻居图中的数据都是有效,这导致图注意力机制可能较强的干扰信息当

作有效信息进行学习,并做出错误判断。对此,我们提出一种基于U-GCN的节点分类算法来改善U-GCN的上述缺陷。该方法主要有两步,第一步,根据图数据中的节点类型、节点特征、边、邻居类型、另据特征等属性计算邻居图重要性值。第二步,在图注意力机制中引入邻居图重要性值,强化主要邻居图的特征表示,弱化次要邻居图的干扰信息。实验结果证明,本文的方法有效地缓解干扰信息的影响,提高模型的精度。本文的贡献如下:

1) 设计一种邻居图的重要性值,衡量邻居图的重要程度,为模型判断学习重点提高依据。

2) 在图注意力机制中引入邻居图重要性值,引导模型有侧重地学习邻居图,提高模型精度。

## 2 相关工作

早期阶段,图数据的处理大多采用统计分析的方法,如网页排序的常用算法PageRank<sup>[10]</sup>、HITS<sup>[11]</sup>等。随着深度学习的崛起,深度学习的模型被引入到图数据中,主要的研究工作是学习更有效的网络嵌入(Network Embedding)<sup>[12]</sup>,这是一种通过约束节点的邻近性为每个节点学习固定长度的表达<sup>[13]</sup>,如DeepWalk<sup>[14]</sup>、LINE<sup>[15]</sup>、node2vec<sup>[16]</sup>等,对比传统地机器学习方法,模型的性能在此阶段得到进一步的提升。

之后,研究发现,图数据存在同质图和异质图的区分。不同于同质图,异质图的中心节点与其邻居的标签大都不同。由于异质性的图数据的被发现,使得算法的泛化研究面临新的挑战。为有效地处理异质性的图数据,Dong等人<sup>[17]</sup>提出metapath2vec模型,该模型公式化基于随机游走的元路径来构建节点的异质邻居,然后利用异质的模型来实现节点嵌入。然而该模型只针对异质性的图数据,模型对同质性图的泛化能力还有待提高。Veličković等人<sup>[18]</sup>提出GAT(Graph Attention Network),通过引入注意力机制,关注节点与其邻居之间的关系,计算图数据中每个节点的表示。这种机制在处理复杂关系、大规模图数据和需要考虑节点重要性的任务中具有很大的优势<sup>[19]</sup>,是一种泛化性较高的机制。相比经典的图神经网络,GAT整体性能更优秀,但对于异质图的学习仍然不尽人意。

基于U-GCN的节点分类近年来,为提高模型处理多种图数据的泛化能力,Jin等提出U-GCN,通过构建三种邻居网络,并使用GAT自适应地学习并融合三种邻居图的特征表示。该模型在兼顾性能



的同时具备强大的泛化能力,可被应用在多种类型的数据集上。此外,该模型融合三种邻居图的方法存在不足,具有改进的空间。HYEONJIN<sup>[20]</sup>等认为由于标注数据集稀少,现有的图神经网络往往泛化能力不足。为此,提出一个新颖的框架,它通过学习一个增强器,以最小化图神经网络在未标注数据上的损失,同时最大化图神经网络在未标注数据上预测的一致性。然而,该框架只关注未标注数据集上的泛化能力,在标注数据集上的性能较为平庸。Guo<sup>[21]</sup>等提出了 HDHGR,这是一种面向同亲性的深度异构图重配方法,通过修改异质图的结构来提高异质神经网络(HGNN)的性能。该方法重点关注于优化异质神经网络对异质图的处理,因此在同质图上的泛化能力较低。Fang<sup>[22]</sup>等提出了一种名为“DropMessage”的新型随机丢弃方法,它可以在消息传递过程中直接对传播的消息执行丢弃操作,通过降低样本方差稳定了训练过程。该方法在同质图上具有较强的扩展性和较高可靠性,在异质图上的效果相对普通。

虽然有不少研究从各个方面改进图神经网络以提升其泛化能力,但是类似于 U-GCN 针对不同类型图数据,提升模型泛化能力的研究较少。此外,由于 U-GCN 在三种邻居图之间的结合性较差,U-GCN 的性能还存在提升的空间,因此,本文提出基于 U-GCN 的节点分类方法来改进三种邻居图的结合,提高模型在多种数据集上的整体性能,有助于提高相关工业应用的生产效率。

### 3 基于 U-GCN 的节点分类算法

本文提出一种基于 U-GCN 的节点分类算法,通过设计一种邻居图重要性公式为每个邻居图计算邻居图重要性值,并在图注意力机制中引入邻居图重要性值,提高邻居图的结合效果,引导模型有侧重地学习邻居图。

#### 3.1 设计邻居图重要性值

图注意力网络采用注意力机制来进行节点之间权重的学习,相比于图卷积神经中节点间的权重是预先确定不变的,图注意力网络中邻居节点对中心节点的贡献不是预先确定的<sup>[23]</sup>。图注意力机制融合三种邻居图存在一个问题,即该方法默认三种邻居图的信息对于算法学习图数据具有相同的有效性。然而,邻居图信息并非完全有效,三种邻居图信息的结合在某些图数据上反而达不到强强联合的效果。我们在多个数据集上进行对比实验。分别使用输入的邻居图全为 1 阶邻居图、全为 2 阶邻居图、全为  $k$  最近邻邻居图的 U-GCN 模型和输入三种不同邻居图的 U-GCN 模型做对比测试。为防止

偶然出现的高指标对实验结论造成误导,测试指标采用 20 轮精准度的平均值以及 20 轮 Macro-F1 的平均值。结果如图 1 和图 2 所示:




图 1 不同邻居图的平均精确度对比

Fig. 1 Comparison of Mean Accuracy of Different Neighborhood Graphs




图 2 不同邻居图的平均 Macro-F1 对比

Fig. 2 Comparison of Mean Macro-F1 of Different Neighborhood Graphs

显然,图 1 和图 2 的结果表明,在 Cora 与 Citeseer 等同质性较强的图数据上,只使用 1 阶邻居图的效果最优,结合三种邻居图的效果略低于前者, $k$  最近邻邻居图的效果最差;在 Cornell、Citeseer 和 Wisconsin 等异质性较强的图数据上,只使用  $k$  最近邻邻居图的效果最佳,而使用三种邻居图的效果略低于前者,1 阶邻居图的效果最差。在各数据集上,使用三种邻居图效果与最优效果差距较小,造成该现象的主要原因是三种邻居图的结合为模型判断提供更多的数据,同时也容易被强大的噪声干扰判断。对此,我们设计一种权重,称这个权重为邻居图重要性值,旨在引导图注意力网络有侧重地融合三种邻居图,缓解强大噪声对模型判断的影响。邻居图重要性值以图数据的节点类型、边的类型、节点的邻居和节点的邻居类型等属性为基础进行

一系列公式计算得出，以下介绍三种邻居图重要性公式的计算。

给定一个图数据  $G = (V, E)$ ，其中  $V = \{v_1, v_2, \dots, v_m\}$  表示图数据中节点的集合， $E$  表示边的集合。对于  $E$  中的每一条边，比较边两端的节点的类型，统计两端节点类型相同的边的数量  $E_s$  和  $E$  中边的总数  $E_a$ 。依照  $E_s$  与  $E_a$  的比例关系，设计 1 阶邻居图重要性公式计算 1 阶邻居图重要性值  $P_1$ ，公式如下：

$$P_1 = \frac{E_s}{E_a} \quad (1)$$

对于每一个节点  $v_i$ ， $i \in \{1, 2, \dots, m\}$ ，统计其邻居的总数  $N_i$  和每一种标签类型的邻居数量  $N_{ci}$ ， $c$  代表标签的类型，取值根据图数据的标签种类  $M$  变化。令  $N_v$  为图数据中拥有边的节点的数量，2 阶邻居图重要性值为  $|P_2|$ ，其中  $P_2$  的计算公式分为三步。首先，计算每个节点每种类型的邻居数量与  $P_1$  的差值，然后对差值进行求和并根据  $N_v$  求均值，最后计算均值与  $\frac{1}{2}$  的差值。 $\frac{1}{2}$  为一个图数据同质性程度的中值，取值为 1 时为强同质性，取值为零时为弱同质性。 $P_2$  的详细计算公式如下：

$$P_2 = \frac{\sum_{n=0}^M \left( \sum_{i=0}^M \left( \frac{N_{ci} - E_s}{N_i - E_a} \right) \right)}{N_v} - \frac{1}{2} \quad (2)$$

而  $k$  最近邻居图重要性值  $P_k$  由  $k$  最近邻居图重要性公式计算，公式如下：

$$P_k = \frac{|P_2|}{P_2(1 + \exp(-|P_2|))} + 1 \quad (3)$$

我们使用一个 sigmoid 函数对  $|P_2|$  求值，然后根据  $P_2$  的正负符号提升或降低  $k$  最近邻权重（默认基础权重为 1），计算后的权重即为  $k$  最近邻居图重要性值  $P_k$ 。

我们在多个数据集上设置实验来验证所计算的邻居图重要性值的真实性与可靠性。三种邻居图的结合本质是一种依照一定比例的特征值叠加，特征值与所占比例成正比，而邻居图重要性影响模型学习的主要因素为三种邻居图重要性值之间的比例关系。因此，本实验为三种邻居图分别设置一个权重，取值范围均为  $[0, 1]$  的实数，为节省计算时间同时保证实验可靠性，在取值范围中进行 100 轮随机采样，所计算的邻居图重要性值会根据比例关系转化为 0 到 1 之间的实数，并与采样的权重进行 Cosine 相似度计算以表现权重变化情况。实验在多个数据集上进行，采用精确度和 Macro-F1 作为指标，结果如图 3 和图 4 所示：

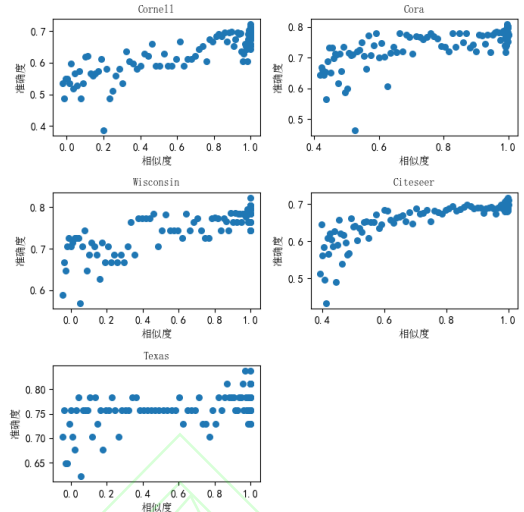


图 3 邻居图重要性值与精确度的关系

Fig. 3 The Relationship between Neighbor Graph Importance and Accuracy

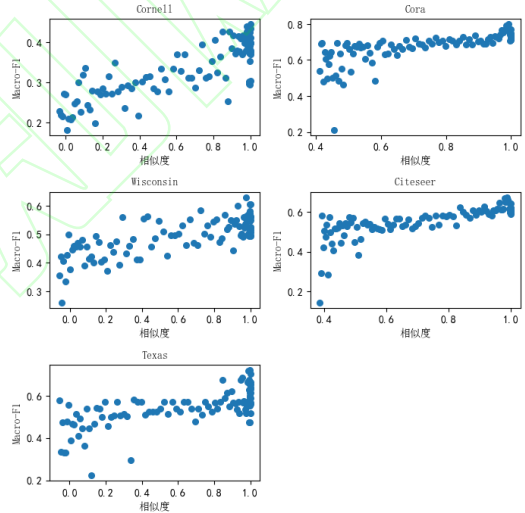


图 4 邻居图重要性值与 Macro-F1 的关系

Fig. 4 The Relationship between Neighbor Graph Importance and Macro-F1

由图 3 和图 4 可以发现，在所有数据集上，权重的比例关系与计算的邻居图重要性值的比例关系越相似，模型的性能越好。说明本文所计算的邻居图重要性值之间的比例关系能够反映出邻居图实际的重要程度。

### 3.2 可变邻居图权重的图注意力网络

我们分别在多头图注意力网络和图级注意力网络中引入三种邻居图重要性值。三种邻居图分别被输入进三个多头图注意力网络中进行邻居聚合，然后再使用一个图级注意力网络自适应融合三种邻居图的图级表示。

在多头注意力网络中，采用拼接的方法聚合特征。令  $v_i^t$  和  $h_i^t$  分别为一种邻居图中的一个节点  $i$  与

其对用的特征, 其中  $t \in \{1, 2, k\}$  表示邻居图的类型。

采用 LeakyReLU 计算一个节点对  $(v_i^t, v_j^t)$  之间的聚

合特征表示  $e_{ij}^t$ 。具体公式如下:

$$e_{ij}^t = \text{LeakyReLU}(u_t[w \cdot P_t \cdot h_i^t | w \cdot P_t \cdot h_j^t]) \quad (4)$$

其中  $u_t$  表示邻居图类型  $t$  的一个参数向量的转置,  $w$  是一个可梯度更新的权重参数,  $P_t$  表示类型为  $t$  的邻居图重要性值。在此, 邻居图重要性值令  $N_i^t$  为节点  $v_i^t$  的邻居集合, 节点对  $(v_i^t, v_j^t)$  的重要性系

数  $a_{ij}^t$  计算方法如下:

$$a_{ij}^t = \frac{\exp(e_{ij}^t)}{\sum_{r \in N_i^t} \exp(e_{ir}^t)} \quad (5)$$

采用 ReLU 为激活函数, 对节点  $i$  进行邻居聚合, 生成与其相对应的节点嵌入  $H_i^t$ :

$$H_i^t = \text{ReLU}\left(\sum_{j \in N_i^t} a_{ij}^t \cdot w \cdot h_j^t\right) \quad (6)$$

为每一个邻居图的节点计算节点嵌入并输入至图级注意力网络中进行融合操作。

在图级注意力网络中, 采用  $\tanh$  函数为激活函数, 对邻居图的每个节点嵌入  $H_i^t$  融入邻居图重要性值, 生成一个与其对应的注意力嵌入  $\beta_i^t$ :

$$\beta_i^t = q \cdot \tanh(W \cdot P_t \cdot (H_i^t)^T + b^t) \quad (7)$$

其中,  $q$  为一个参数向量,  $W$  为权重参数,  $P_t$  为类型为  $t$  的邻居图重要性值,  $b^t$  表示一个偏差。为每一个邻居图中的节点嵌入生成注意力嵌入后, 采用 softmax 函数计算每一个节点嵌入的注意力系数  $\gamma_i^t$ :

$$\gamma_i^t = \text{softmax}(\beta_i^t) = \frac{\exp(\beta_i^t)}{\sum_t \exp(\beta_i^t)} \quad (8)$$

$\gamma_i^t$  越大类型为  $t$  的邻居图中的节点嵌入越重要。依照注意力系数, 采用求和操作融合三种邻居图的节点嵌入:

$$F_i = \sum_t \gamma_i^t \cdot H_i^t \quad (9)$$

$F_i$  表示节点  $v_i$  的融合嵌入, 其融合了三种邻居图中节点  $i$  对应的节点嵌入。本文模型的结构如图 5 所示:

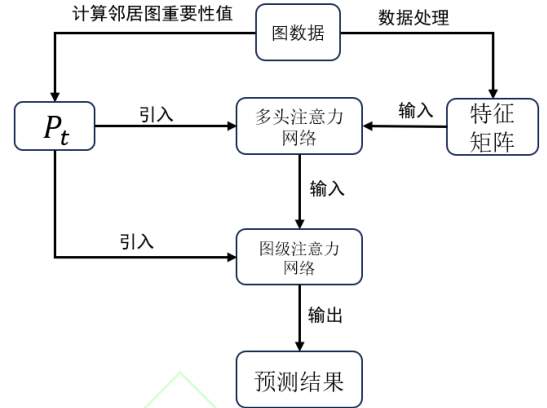


图 5 可变邻居图权重模型结构图

Fig. 5 Structure of the variable neighborhood graph weights model

## 4 实验与分析

### 4.1 数据集与平台参数

实验运行在 Intel Core i7-13650HX CPU 与 NVIDIA GeForce RTX 4060 Laptop GPU 服务器上, 服务器操作系统为 Windows 11。Python 版本为 3.8.5, Pytorch 框架为 2.2.1, CUDA 框架为 12.1。数据集分别采用两个引文网络 Cora 和 Citeseer<sup>[24]</sup>, 三个网页网络 Cornell、Wisconsin 和 Texas<sup>[25]</sup>, 数据集详情如表 1 所示。模型的学习率为 0.005, 权重衰减为  $5e-3$ , dropout 为 0.4, 迭代次数为 1000, 使用 Adam 优化器训练。 $k$  最近邻邻居的相似度指标为 Cosine 相似度, 并依照 U-GCN 的设置, 分别对 Cora、Citeseer、Cornell、Wisconsin、Texas 的设置 3, 3, 8, 8, 8。

表 1 数据集信息

Tab.1 Dataset information

数据集	类别	节点	边	特征
Cora	7	2708	5429	1433
Citeseer	6	3327	4732	3703
Cornell	5	183	295	1703
Wisconsin	5	251	499	1703
Texas	5	183	309	1703

### 4.2 对比试验

对比实验选取多个图领域的经典算法与本文模型做对比, 分别为 GCN、GAT、DeeperGCN<sup>[26]</sup>、 $k$ -GNNs<sup>[27]</sup>、U-GCN。实验采用四个指标评测模型性能, 分别为 20 轮实验的精准度的均值、最高精准度、20 轮实验的



Macro-F1 的平均值和最大 Macro-F1。其中 20 轮实验精准度的均值越高,模型的性能越优秀,可以评估模型的整体性能及稳定性。Macro-F1 的作用主要是评估模型在多个类别上的平均性能,尤其是当各类别的样本数量不均衡时,Macro-F1 可以评估模型的多分类能力。平均 Macro-F1 用以评估模型的多分类能力的稳定程度。对比实验结果见下列表格:

表 2 各模型 20 轮实验的精确度的平均值比较

Tab.2 Comparison of mean values of accuracy for 20 rounds of experiments for each model

模型	Cora	Citeseer	Cornell	Wisconsin	Texas
GCN	77.98	65.38	47.45	49.25	56.44
GAT	75.50	65.36	48.47	54.12	54.40
DeeperGCN	49.50	39.28	66.01	69.62	66.77
k-GNNs	72.72	59.86	68.47	61.25	68.64
U-GCN	79.21	68.34	66.25	71.15	75.49
Ours	79.54	70.90	69.26	77.25	78.78

表 3 各模型的最高精确度对比

Tab.3 Comparison of maximum accuracy of each models

模型	Cora	Citeseer	Cornell	Wisconsin	Texas
GCN	79.20	69.40	50.84	56.25	62.71
GAT	78.00	68.00	55.93	61.25	59.32
DeeperGCN	56.00	50.20	72.88	76.25	74.57
k-GNNs	76.20	63.00	74.57	71.25	71.18
U-GCN	81.22	69.65	72.88	76.47	78.31
Ours	81.70	72.20	74.63	80.39	83.78

表 4 各模型 20 轮实验的 Macro-F1 的平均值对比

Tab.4 Comparison of the mean values of Macro-F1 for 20 rounds of experiments for each model

模型	Cora	Citeseer	Cornell	Wisconsin	Texas
GCN	76.60	62.05	20.71	25.48	21.19
GAT	74.48	61.67	27.88	27.13	18.72
DeeperGCN	47.31	33.04	39.90	41.36	37.03
k-GNNs	71.89	56.16	48.84	39.02	41.23
U-GCN	78.49	65.28	36.22	46.91	53.13
Ours	78.57	67.64	39.72	56.90	61.68

表 5 各模型的最高 Macro-F1 对比

Tab.5 Comparison of highest Macro-F1 for each model

模型	Cora	Citeseer	Cornell	Wisconsin	Texas
GCN	77.50	65.50	28.66	31.00	30.52
GAT	77.15	64.86	39.92	37.52	23.48
DeeperGCN	79.64	48.28	56.38	45.39	45.74
k-GNNs	76.06	60.23	56.91	51.02	47.50
U-GCN	79.60	66.43	45.81	53.76	56.67
Ours	80.26	69.05	46.41	61.92	76.57

本文模型在 20 轮精确度的平均值在 5 个数据集上均优于对比模型,在数据集 Cora、Citeseer、Wisconsin 和 Texas 上,对比最优基线 U-GCN 分别提升 0.33%、2.56%、6.1%、3.29%,在数据集 Cornell 上,对比最优模型 k-GNNs 提升 0.79%。在最高精确度指标上,在数据集 Cora、Citeseer、Cornell、Wisconsin 和 Texas 上,对比原模型 U-GCN 分别提升 0.48%、2.55%、1.75%、3.92%和 5.47%。两种精确度指标上的结果证明引入邻居图重要性值有助于模型表达能力的提升,并且这种提升是可靠且有效。

对比各模型的 20 轮 Macro-F1 的平均值的实验结果,本文模型在各个数据集上均优于 U-GCN。在 Cora、Citeseer、Wisconsin、Texas 等数据集上,对比最优基线 U-GCN 分别高出 0.08%、2.36%、6.94%、8.55%。在最高 Macro-F1 指标上,本文模型在各个数据集上均优于 U-GCN,依照表格数据集从左往右排序,分别提高 0.66%、3.62%、0.6%、8.16%、19.9%。两个 Macro-F1 指标的结果证明,本末模型在多个类别上的平均精度均有明显地提升。

综上实验证明,我们提出的可变权重邻居图融合方法能够自适应地改变邻居图在节点嵌入中的权重,有侧重地学习邻居图,提高三种邻居图的结合性。

#### 4.3 消融实验

为证明引入的邻居图重要性值对模型的有效性,我们设置了四个模型做对比实验。四个模型分别为:基础模型 U-GCN;在多头注意力网络中引入邻居图重要性值的 U-GCN 模型,成为 ours1;在图级注意力网络中引入邻居图重要性值的 U-GCN 模型,成为 ours2;完整的本文模型 ours。实验采用 20 轮精准度的平均值以及最高精准度为指标,数据集使用 Cora、Citeseer、Cornell、Wisconsin 和 Texas。实验结果如下表所示:

表 6 消融实验结果

Tab.6 Results of ablation experiment

模型	Cora	Citeseer	Cornell	Wisconsin	Texas
U-GCN	79.18	67.34	66.31	71.24	75.28
ours1	79.84	69.82	66.70	71.41	75.83
ours2	79.01	67.02	69.88	76.27	77.83
ours	79.50	70.77	68.21	77.26	78.77

消融实验的结果表明,对比 UGCN, ours1 和 ours2 在各个数据集上均有提升,其中,ours1 在 Cora 和 Citeseer 提升较高,分别提升 0.66%和 2.48%。因此,在多头图注意力网络中引入邻居图重要性值有助于模型生成有效性更高的节点嵌入,从而引导模型做出正确的判断。虽然 ours2 在 Cora、Citeseer

数据集上有所降低,但是在 Cornell、Wisconsin、Texas 数据集上却有极大的提升,分别提升 1.9%、6.02%和 3.49%。由于只在图级图注意力网络中引入邻居图重要性值,ours2 可以有效地改变邻居图的权重,使部分邻居图的信息在融合嵌入能够占主导地位。但也因此放大部分干扰信息,误导模型的判断,特别是在 Cora 和 Citeseer 等引文网络中,部分标签的节点数量太少,使得这类节点反而成为噪声,有时甚至主导模型的判断。除 Cora 外,模型 ours 在其它数据集上的精度最高。显然,在两种图注意力网络中均引入邻居图重要性值不仅降低噪声对模型的影响,而且相互助长,进一步提高三种邻居图的结合性,最终得到更优的整体效果。

综上所述,两个图注意力网络的改进方法都在一定程度上提高模型在节点分类任务上的精确度。我们提出的模型有效地改善 U-GCN 融合三种邻居图的缺陷,表现出更优秀的泛化性能和判断精确度。

## 5 结束语

由于 U-GCN 融合三种邻居图的方法存在邻居图之间可能相互干扰的缺陷,我们提出一种基于 U-GCN 的可变邻居图权重的模型,缓解邻居图之间的噪声干扰,提高三种邻居图的结合性,进一步提升 U-GCN 的泛化能力。我们设计一种邻居图重要性公式为每个邻居图计算邻居图重要性值,并将其引入两个图注意力网络中。多个对比实验证明本文模型具有高的可靠性和令人满意的性能。

后续我们继续深入研究,为每一个节点分配一个权重,从而进一步减少噪声的影响,提高多种邻居图的结合性,并在多个数据集上进行实验,保证模型的泛化能力和可靠性。

## 参考文献

- [1] 吴博,梁循,张树森,等. 图神经网络前沿进展与应用[J]. 计算机学报,2022,45(1):35-68.DOI:10.11897/SP.J.1016.2022.00035.  
WU B,LIANGX,Zhang S S,et al. Advances and applications in graph neural networks[J].Chinese Journal of Computers,2022,45(1):35-68.DOI:10.11897/SP.J.1016.2022.00035.
- [2] 刘杰,尚学群,宋凌云,等. 图神经网络在复杂图挖掘上的研究进展[J]. 软件学报,2022,33(10):3582-3618.DOI:10.13328/j.cnki.jos.006626.  
Liu J,ShangXQ,SongLY,et al. Progress of graph neural networks on complex graph mining[J]. Journal of Software,2022,33(10):3582-3618.DOI:10.13328/j.cnki.jos.006626
- [3] Kipf T N,WellingM.Semi-supervised classificationwithgraph convolutional networks[J].arXiv:1609.02907,2016.DOI:10.48550/arXiv.1609.02907.
- [4] Scarselli F, Gori M, Tsoi AC,etal.The graph neural network model. IEEE transactions on neural networks. 2008 Dec 9;20(1):61-80.DOI:10.1109/TNN.2008.2005605
- [5] McphersonM,Cook S L M.Birds of a Feather: Homophily in Social Networks[J].Annual Review of Sociology,2001,27:415-444.DOI:10.1146/annurev.soc.27.1.415.
- [6] Mej. N.Assortative mixing in networks [J].Physical review letters,2002(20):89.
- [7] Zhu J ,Yan Y, Zhao L,etal.Beyond Homophily in Graph Neural Networks: Current Limitations and Effective Designs[C]//Proceedings of the 34th International Conference on Neural Information Processing Systems.Vancouver,Canada:Curran Associates Inc,2020:7793-7804.DOI:10.48550/arXiv.2006.11468.
- [8] Pandit,Shashank,Chau,etal.Netprobe: a fast and scalable system for fraud detection in online auction networks[C]//Proceedings of the 16th international conference on World Wide Web.Banff Alberta Canada:Association for Computing Machinery,2007:201-210.DOI:10.1145/1242572.1242600.
- [9] Jin D,YuZ,HuoC,etal.Universal Graph Convolutional Networks[C]//Processing Systems 34 - 35th Conference on Neural Information Processing Systems, NeurIPS2021.Virtual, Online:Neural information processing systems foundation, 2021:10654-10664.
- [10] Page L , Brin S , Motwani R ,et al.Thepagerank citation ranking: Bringing order to the web, in world wide web internet and web information systems[C]//Processing of the 7th International World Wide Web Conf.Stanford Digital Library working paper,1998:72.
- [11] Jon,M,Kleinberg.Hubs, authorities, and



- communities[J].ACM Computing Surveys,1999,31(4):5.DOI:10.1145/345966.345982.
- [12] 齐金山,梁循,李志宇,et al.大规模复杂信息网络表示学习:概念、方法与挑战[J].计算机学报,2018,41(10):27.DOI:10.11897/SP.J.1016.2018.02394.  
QI JS,LIANGZ,LI ZY,et al. Large-scale complex information network representation learning:concepts,methodsand challenges[J]. Chinese journal of computers,2018,41(10):27.DOI:10.11897/SP.J.1016.2018.02394.
- [13] 徐冰冰,岑科廷,黄俊杰,等.图卷积神经网络综述[J].计算机学报,2020,43(5):26.DOI:10.11897/SP.J.1016.2020.00755.  
Xu B B,Chen K T,Huang J J,et al. A review of graph convolutional neural networks[J].Chinese journal of computers,2020,43(5):26.DOI:10.11897/SP.J.1016.2020.00755.
- [14] Perozzi B , Al-Rfou R , Skiena S .DeepWalk: Online Learning of Social Representations[C]//Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining.New York:Association for Computing Machinery,2014:701-710.DOI:10.1145/2623330.2623732.
- [15] Tang J , Qu M , Wang M ,et al.LINE: Large-scale Information Network Embedding[C]//Proceedings of the 24th International Conference on World Wide Web.FlorenceItaly:International World Wide Web Conferences Steering Committee,2015:1067-1077.DOI:10.1145/2736277.2741093.
- [16] Grover A,LeskovecJ.node2vec: Scalable Feature Learning for Networks[C]//Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining.CaliforniaUSA:Association for Computing Machinery,2016:855-864.DOI:10.1145/2939672.2939754.
- [17] Dong Y,Chawla N V,SwamiA.metapath2vec: Scalable Representation Learning for Heterogeneous Networks[C]//Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining.HalifaxNS Canada:Association for Computing Machinery,2017:135-144.DOI:10.1145/3097983.3098036.
- [18] VeličkovićP,CucurullG,CasanovaA,etal.Graph attention networks[J].arxivpreprint,2017:arxiv:1710.10903 .DOI:10.48550/arXiv.1710.10903
- [19] 陈丹阳,张长伦.注意力机制在图神经网络模型中的算法研究[J].建模与仿真,2024,13(1):225-238.DOI:10.12677/MOS.2024.131022.  
Chen D Y,Zhang C L. Algorithm Research of Attention Mechanism in Graph Neural Network Model[J].Modelling and Simulation,2024,13(1):225-238.DOI:10.12677/MOS.2024.131022.
- [20] ParkH,Lee S,Hwang D,etal.Learning Augmentation for GNNs With Consistency Regularization[J].IEEE Access,2021,(9):127961-127972.DOI:10.1109/ACCESS.2021.3111908.
- [21] GUO J Y,DuL,Bi W D,et al. Homophily-oriented Heterogeneous Graph Rewiring[C]//Proceedings of the ACM Web Conference 2023.New York, USA:Association for Computing Machinery,2023:3476-3484.DOI:10.1145/3543507.3583454.
- [22] Fang T ,XiaoZ,WangC,etal.DropMessage: Unifying Random Dropping for Graph Neural Networks[J].arxivpreprint,2022,arxiv:2204.10037.DOI:10.48550/arXiv.2204.10037.
- [23] 刘俊奇,涂文轩,祝恩.图卷积神经网络综述[J].计算机工程与科学,2023,45(8):1472-1481.DOI:10.3969/j.issn.1007-130X.2023.08.016.  
LIU JQ,TU WX,ZHU E. Survey on graph convolutional neural network[J].Computer Engineering & Science,2023,45(08):1472-1481.DOI:10.3969/j.issn.1007-130X.2023.08.016.
- [24] Sen P,NamataG,BilgicM,etal.Collective Classification in Network Data[J].Ai Magazine,2008,29(3):93-106.  
DOI:10.1017/S0890060408000279.
- [25] Pei H,WeiB,Chang C C,etal.Geom-GCN: Geometric Graph Convolutional Networks[J].Pei, H., Wei, B., Chang, K. C. C., Lei, Y., & Yang, B. (2020). Geom-gcn: Geometric graph

convolutional networks.arxivpreprint ,2020,arxiv:  
2002.05287.DOI:10.48550/arXiv.2002.05287

- [26] Li G,XiongC,ThabetA,etal.DeeperGCN: All You  
Need to Train Deeper  
GCNs[J].arxivpreprint,2020,arxiv:2006.07739.D  
OI:10.48550/arXiv.2006.07739.
- [27] Morris C,RitzertM,FeyM,etal.Weisfeiler and  
Leman Go Neural: Higher-order Graph Neural  
Networks[C]//Proceedings of the Thirty-Third  
AAAI Conference on Artificial Intelligence and  
Thirty-First Innovative Applications of Artificial  
Intelligence Conference and Ninth AAAI  
Symposium on Educational Advances in  
Artificial  
Intelligence.HawaiiUSA:AAAI Press,2019:  
4602-4609.DOI: 10.1609/aaai.v33i01.33014602.